사출성형 공정 데이터 기반 품질 이상 예측 및 검사 우선순위 모델 개발

안영잘부_정지혜, 윤효원

1. 서론

1.1 과제 배경 및 연구 목적

사출성형(Injection Molding)은 온도, 압력, 속도, 시간 등 다양한 공정조건이 제품 품질에 복합적으로 영향을 미치는 제조 공정이다. 제조 현장에서는 생산 이후 품질검사를 통해 제품의 이상 여부를 확인하는 경우가 많기 때문에, 최종검사 이전 단계에서 불량 가능성이 높은 제품을 사전에 선별할 수 있다면 제한된 검사 자원을 보다 효율적으로 활용할 수 있다.

본 연구에서는 KAMP에서 제공한 자동차 부품 사출성형 공정 데이터(CN7, RG3)를 활용하여 **최종 품질검사 이전에 제품의 불량 위험도를 예측하고, 예측 결과를 기반으로 검사 우선순위를 결정하는 머신러닝 모델을 개발**하였다.

단순히 정상·불량을 분류하는 모델의 성능을 높이는 것에 그치지 않고, 실제 제조 데이터에서 모델이 효과적으로 작동하는 조건과 예측이 어려운 조건을 분석하였다. 또한 모델이 산출한 Risk Score를 활용하여 제한된 검사 비율에서 실제 불량을 얼마나 탐지할 수 있는지를 평가하고, 이를 기반으로 위험도 기반 검사 우선순위 전략을 제안하였다.

1.2 데이터 개요

본 연구에서는 **경진대회에서 제공된 학습용 가공 데이터**를 기본 분석 데이터로 사용하였으며, 데이터의 생산 구조를 파악하고 가공 과정에서 제외된 메타정보를 보완하기 위해 **KAMP에서 공개한 「사출성형기 AI 데이터셋」의 원천 및 추가 데이터를 별도로 다운로드하여 함께 활용하였다.** 추가 데이터의 상세한 활용 방법과 모델 반영 여부는 3.5절에서 설명한다.

최종 모델 학습에 사용한 가공 데이터는 CN7과 RG3 두 차종의 사출성형 공정 데이터로 구성되어 있다. CN7은 총 1,211건 중 정상 1,194건, 불량 17건이며, RG3는 총 1,182건 중 정상 1,157건, 불량 25건으로 두 데이터 모두 정상 제품에 비해 불량 제품의 비율이 매우 낮은 클래스 불균형 특성을 가진다.

모델의 기본 입력변수는 `Injection_Time`, `Filling_Time`, `Plasticizing_Time`, `Max_Injection_Speed`, `Max_Injection_Pressure`, 배럴 및 금형 온도 등 **24개의 주요 공정변수**로 구성하였다.

추가로 확보한 KAMP 원천 데이터에서는 가공 데이터와의 대응관계를 확인한 후 `TimeStamp`, `PART_NAME` 등의 생산 메타정보를 복원하였다. 이를 통해 동일 Shot에서 생산된 LH/RH 제품의 구조를 분석하고, 제품 위치를 나타내는 `Side`, 생산 시각을 활용한 `Cyclic Hour`, 직전 Shot 대비 공정 변화량인 `Delta Feature` 등을 생성하였다.

구분	CN7	RG3
학습 데이터	1,211건	1,182건
정상	1,194건	1,157건
불량	17건	25건
기본 공정변수	24개	24개
추가 메타정보	TimeStamp, PART_NAME 등	TimeStamp, PART_NAME 등

또한 외부 환경요인의 영향을 탐색하기 위한 추가 실험에서는 **기상청 기상관측 데이터**를 결합하여 분석하였다. 다만 기상 데이터는 시간적 교란 가능성을 고려하여 최종 모델에서는 제외하였다.

1.3 분석 목표 및 핵심 문제 정의

본 연구에서는 다음 세 가지를 주요 분석 목표로 설정하였다.

첫째, 공정변수를 활용하여 최종검사 이전에 제품의 불량 위험도를 예측한다.

둘째, 전체 제품을 동일하게 검사하는 방식이 아니라 모델의 Risk Score를 기준으로 고위험 제품을 우선 검사할 수 있는 **Inspection Priority System**을 구축한다.

셋째, 모델이 불량을 효과적으로 탐지하는 조건뿐 아니라 예측에 실패하는 조건을 데이터 구조의 관점에서 분석한다.

데이터를 분석하는 과정에서 특히 중요한 문제로 **동일 Shot의 Label Conflict**가 확인되었다. 동일한 TimeStamp에서 생산된 LH/RH 제품이 24개의 공정변수를 동일하게 공유함에도 불구하고 서로 다른 품질 결과를 가지는 경우가 존재하였다.

CN7에서는 11개의 conflict group이 확인되었으며 전체 불량 17건 중 11건(64.7%)이 해당 구조에 포함되었다. RG3에서는 25개의 conflict group이 확인되었으며 전체 불량 25건이 모두 해당 구조에 포함되었다.

특히 RG3에서는 불량이 발생한 모든 conflict shot에서 **LH는 정상, RH는 불량**이었으며, 동일 shot 내 LH/RH의 24개 공정변수 값의 최대 차이는 0이었다.

이는 현재 제공된 설비 단위 공정변수만으로는 일부 제품 위치별 품질 차이를 충분히 설명하기 어려운 **정보적 한계**가 존재함을 의미한다.

---

2. 데이터 이해 및 탐색적 분석

2.1 Raw–Processed 데이터 연결 및 메타정보 복원

제공된 가공 데이터에는 모델 학습에 필요한 공정변수가 포함되어 있었지만 제품 위치(Side)와 생산 시각(TimeStamp) 등 일부 메타정보가 포함되어 있지 않았다.

이에 원천 데이터와 가공 데이터를 비교하여 데이터 간 대응관계를 확인하고, 각 제품의 `_id`, `TimeStamp`, `PART_NAME` 등의 메타정보를 연결하였다.

CN7과 RG3 모두 원천 데이터와 가공 데이터의 주요 공정변수 간 상관계수가 1.0으로 확인되어 데이터 대응관계가 일치함을 검증하였다. 이후 `PART_NAME` 정보를 활용하여 제품의 LH/RH 위치를 Side 변수로 생성하였다.

이 과정을 통해 단순 공정변수 분석을 넘어 **생산 시각 및 제품 위치를 포함한 데이터 구조 분석**이 가능해졌다.

2.2 동일 Shot LH/RH 구조 및 Label Conflict 분석

TimeStamp를 기준으로 생산 구조를 분석한 결과, 동일 시각의 LH/RH 제품은 동일한 공정변수를 공유하는 경우가 확인되었다.

CN7에서는 606개의 고유 공정조건 그룹 가운데 11개 그룹에서 동일한 입력변수에 대해 정상과 불량 라벨이 동시에 존재하였다. 해당 conflict 구조에는 전체 불량 17건 중 11건(64.7%)이 포함되었다.

RG3에서는 591개의 공정조건 그룹 중 25개에서 Label Conflict가 확인되었으며, 전체 불량 25건이 모두 conflict group에 포함되었다. 특히 모든 경우에서 동일 shot의 LH 제품은 정상, RH 제품은 불량이었다.

따라서 **동일한 24개 공정변수만으로 개별 LH/RH 제품의 품질을 완전히 분리하는 것은 구조적으로 어려울 수 있음**을 확인하였다.

이는 이후 모델 검증 방법과 RG3 모델의 성능을 해석하는 중요한 기준으로 활용하였다.

2.3 CN7 불량 특성 분석

CN7의 정상 및 불량 제품을 비교한 결과 일부 불량 구간에서는 여러 공정변수가 동시에 정상 범위를 크게 벗어나는 현상이 확인되었다.

특히 일부 연속 불량 구간에서 `Max_Injection_Speed`가 크게 증가하는 동시에 `Filling_Time`, `Injection_Time`, `Cushion_Position`, `Max_Injection_Pressure` 등 여러 공정변수가 정상 데이터와 큰 차이를 보였다.

이는 특정 단일 변수의 변화보다는 **사출·충진 단계에서 여러 공정변수가 동시에 변화하는 복합적인 공정상태와 불량이 함께 발생한 사례**로 해석하였다.

반면 일부 가스 불량에서는 $|Z| \geq 3$ 수준의 뚜렷한 단일 공정변수 이상이 나타나지 않았다. 따라서 CN7에서도 현재 공정센서를 통해 비교적 쉽게 탐지할 수 있는 불량과 동일 공정정보만으로 구분하기 어려운 불량이 함께 존재하는 것으로 분석하였다.

2.4 RG3 불량 특성 분석

RG3에서는 전체 불량 25건이 모두 RH 제품에서 발생하였다.

그러나 정상 데이터를 기준으로 각 공정변수의 이상 정도를 분석한 결과 25개 불량 중 24건에서는 개별 공정변수가 $|Z| \geq 3$ 수준의 극단적인 이상을 보이지 않았다.

또한 불량이 발생한 모든 shot에서 동일 시각의 LH 제품은 정상으로 판정되었으며, LH/RH 제품 사이의 24개 공정변수 값은 완전히 동일하였다.

따라서 RG3의 경우 단순히 설비 센서의 극단적인 이상 여부만으로 개별 제품의 불량을 설명하기 어려웠다. 다중 캐비티 환경에서는 캐비티별 압력·온도, 유동 상태 등 현재 데이터에 포함되지 않은 정보가 추가적으로 필요할 가능성이 있으나, 제공된 데이터만으로 구체적인 물리적 원인을 확정하지 않았다.

2.5 공정변수의 시간적 변화 및 데이터 품질 분석

일부 공정변수에서는 생산 기간에 따라 값의 분포가 크게 변화하는 현상이 확인되었다.

대표적으로 `Average_Screw_RPM`은 CN7과 RG3 모두 특정 시점을 기준으로 약 290 수준에서 약 29 수준으로 변화하였다. 반면 `Max_Screw_RPM`은 같은 기간 약 30 수준을 유지하였다.

이러한 변화가 실제 공정조건의 변경인지, 측정 단위·수집 방식 또는 전처리 과정의 변화인지 제공 데이터만으로 확정하기 어려웠다. 따라서 이를 단순한 이상치로 제거하지 않고 **시간적 일반화 및 데이터 품질 측면에서 고려해야 하는 잠재적 위험요인**으로 판단하였다.

2.6 Feature Engineering 및 추가 변수 설계

기본 24개 공정변수만으로 표현하기 어려운 **공정변수 간 관계, 생산시간의 특성, 연속된 Shot 간 공정상태 변화 및 제품 위치에 따른 차이**를 반영하기 위해 추가적인 Feature Engineering을 수행하였다.

먼저 사출성형 공정에서 서로 연관된 변수 간 관계를 반영하기 위해 원천 공정값을 활용하여 비율, 차이 및 상호작용 변수를 생성하였다. 대표적으로 사출속도와 압력의 상호작용, 충진시간과 사출시간의 비율, 계량시간과 전체 Cycle Time의 비율, 사출압력과 보압 전환 시점 압력의 차이 등을 실험하였다. 가공 데이터는 표준화된 값으로 구성되어 있으므로 변수 간 비율이나 상호작용의 물리적 의미가 달라질 수 있다고 판단하여, KAMP

원천 데이터와 가공 데이터를 연결한 뒤 **원 단위 공정값을 기준으로 파생변수를 생성하였다.** 그러나 이러한 공정 관계 기반 변수들은 고정된 검증조건에서 검사 우선순위 성능을 일관되게 개선하지 못하여 최종 모델에서는 제외하였다.

생산시간에 따른 특성을 반영하기 위해 원천 데이터의 `TimeStamp`에서 시·분·초를 포함한 생산시간을 추출하였다. 시간은 23시와 0시가 실제로 인접함에도 일반적인 연속형 변수에서는 멀리 떨어진 값으로 표현되는 문제가 있으므로, 24시간의 순환성을 반영한 `Hour_sin`, `Hour_cos`의 **Cyclic Hour**를 생성하였다.

$$Hour_{sin} = \sin\left(\frac{2\pi \cdot Hour}{24}\right)$$

$$Hour_{cos} = \cos\left(\frac{2\pi \cdot Hour}{24}\right)$$

또한 개별 Shot의 절대적인 공정값뿐만 아니라 **직전 Shot 대비 공정상태의 변화**가 불량 탐지에 유효한지를 확인하기 위해 Delta Feature를 생성하였다. 동일 `TimeStamp`에서 생산된 LH/RH 제품을 하나의 Shot으로 정의하고 생산시간 순으로 정렬한 뒤, 현재 Shot과 직전 Shot의 공정값 차이를 계산하였다.

$$\Delta X_t = X_t - X_{t-1}$$

CN7에서는 여러 공정변수에 대한 변화량을 검토한 결과 `Max_Injection_Speed`, `Max_Injection_Pressure`, `Filling_Time`, `Plasticizing_Time`의 4개 Delta Feature를 주요 후보로 선정하였다. Delta Feature만 추가한 경우에는 기본 모델 대비 성능 개선이 나타나지 않았지만, Cyclic Hour와 함께 적용했을 때 검사 우선순위 성능이 가장 높게 나타났다. 이에 최종 CN7 모델에는 **24개 기본 공정변수, 2개 Cyclic Hour, 4개 Delta Feature의 총 30개 변수**를 사용하였다.

RG3에서는 불량이 RH 제품에 집중되는 특성이 확인됨에 따라 KAMP 원천 데이터의 `PART_NAME` 정보를 이용하여 LH/RH 제품 위치를 복원하고 `Side_RH` 변수를 생성하였다. `Side_RH`는 제품 생산 시점에 확인 가능한 정보로 판단하여 모델 입력변수로 활용하였다. 다만 RH 자체를 불량의 직접적인 원인으로 해석하지 않고, 기존 24개 설비 공정변수만으로 표현되지 않는 **제품 위치에 따른 위험도 차이를 나타내는 정보**로 활용하였다.

추가적으로 최근 Shot의 공정이력을 반영하는 Rolling Feature와 동일 Shot의 LH/RH 데이터를 하나의 생산단위로 재구성하는 Shot-level 접근도 검토하였다. 그러나 고정된 검증조건에서 검사 우선순위 성능의 충분한 개선이 확인되지 않아 최종 모델에서는 제외하였다.

최종적으로 파생변수는 단순히 생성 가능한 변수를 모두 사용하는 것이 아니라, **공정적 의미와 예측시점에서의 활용 가능성을 검토하고 동일한 검증조건에서 실제 검사 우선순위 성능 개선이 확인된 변수만 선택하는 방식**으로 선정하였다.

구분	대표 변수·방법	설계 목적	최종 적용
공정 상호작용	Speed–Pressure Interaction	사출속도와 압력의 복합 관계 반영	제외
공정 비율	Filling/Injection Ratio	충진시간과 사출시간의 상대적 관계 반영	제외
공정 비율	Plasticizing/Cycle Ratio	전체 Cycle 대비 계량공정 비율 반영	제외
공정 차이	Injection–Switch-over Pressure Difference	사출압력과 보압 전환 압력의 차이 반영	제외
시간 특성	Hour_sin, Hour_cos	생산시간의 24시간 주기성 반영	**CN7 적용**
Shot 변화량	4개 Delta Feature	직전 Shot 대비 주요 공정상태 변화 반영	**CN7 적용**

구분	대표 변수·방법	설계 목적	최종 적용
제품 위치	Side_RH	LH/RH 제품 위치에 따른 차이 반영	**RG3 적용**
공정 이력	Rolling Feature	최근 Shot의 공정상태 및 변동 반영	제외
Shot 단위 재구성	Shot-level Modeling	동일 Shot의 LH/RH 정보를 하나의 생산단위로 분석	제외

최종 채택 여부는 3장의 모델링 실험을 통해 결정하였다.

3. 모델링 및 검증

3.1 데이터 누수 방지를 위한 검증 전략

동일 shot의 LH/RH 제품이 동일한 공정변수를 공유하기 때문에 일반적인 Random Split을 사용할 경우 동일 shot의 제품이 학습 데이터와 검증 데이터에 각각 포함될 가능성이 있다. 이 경우 모델이 유사한 입력값을 이미 학습한 상태에서 검증하게 되어 실제보다 성능이 높게 측정될 수 있다.

이를 방지하기 위해 CN7에서는 **TimeStamp를 그룹으로 설정한 StratifiedGroupKFold 4-Fold 교차검증**을 적용하였다. 동일 shot의 LH/RH 제품이 반드시 동일 fold에 배정되도록 하여 데이터 누수 가능성을 최소화하였다.

RG3는 시간에 따른 모델의 일반화 가능성을 확인하기 위해 과거 생산 데이터를 학습하고 이후 생산 데이터를 평가하는 **Chronological Split**을 적용하였다.

이를 통해 단순 Random Split보다 실제 생산환경에 가까운 조건에서 모델의 성능을 평가하고자 하였다.

3.2 평가 지표

두 데이터 모두 불량 비율이 매우 낮기 때문에 Accuracy만으로 모델 성능을 평가하지 않았다.

ROC-AUC와 함께 불균형 데이터에서 양성 클래스 탐지 성능을 보다 직접적으로 반영하는 PR-AUC를 사용하였으며, 실제 검사 운영을 고려하여 **Top-k Inspection Budget Recall**을 주요 운영 지표로 설정하였다.

Top-k Inspection Budget Recall은 모델이 산출한 Risk Score 상위 k%의 제품만 우선 검사한다고 가정했을 때 전체 실제 불량 중 몇 %를 탐지할 수 있는지를 나타낸다.

이를 통해 단순 분류 성능을 넘어 **제한된 검사 자원을 어떤 제품에 우선 배정해야 하는가**를 평가하였다.

3.3 단계별 모델링 및 후보 모델 비교

본 연구에서는 단일 모델의 성능을 비교하여 최종 모델을 결정하기보다, 데이터 구조와 클래스 불균형, 시간적 특성 및 공정 변화정보를 단계적으로 반영하는 방식으로 모델링을 수행하였다. 특히 최종 목적이 단순한 정상·불량 분류가 아니라 제한된 검사량에서 불량 제품을 우선적으로 선별하는 것이므로 ROC-AUC와 함께 PR-AUC 및 Top-k Recall을 주요 평가 지표로 사용하였다.

또한 CN7과 RG3는 불량 발생 형태와 데이터 구조가 서로 다르게 나타났기 때문에 동일한 모델을 일괄적으로 적용하지 않고 금형별로 모델링 및 검증을 수행하였다.

단계	**주요 실험**	**목적**	**주요 결과**
1차	LR, RF, IF 등 Baseline	기본 공정변수의 예측 가능성 및 시간적 일반화 확인	CN7과 RG3의 성능 및 데이터 특성 차이 확인

단계	주요 실험	목적	주요 결과
2차	Grouped CV, RF/XGB 비교, 공정 파생변수, 소규모 튜닝	데이터 누수 방지 및 공정관계 반영	CN7은 공정변수만으로 비교적 높은 성능, RG3는 Side 추가 시 개선
3차	Class Weight, ROS, RUS, SMOTE	클래스 불균형 처리방법 비교	Sampling의 일관된 개선이 없어 Class Weight 유지
4차	ExtraTrees, Soft Voting, Cyclic Hour, Delta Feature	모델 구조·시간·Shot 변화정보 검증	CN7은 ET+Hour+Delta 개선, RG3는 추가정보 효과 제한
5차	RG3 RH-only, 5/20 Shot Rolling Feature	Side 효과 분리 및 RH 내부 불량 구분 가능성 검증	RH 내부 구분 성능이 낮고 Rolling Feature도 개선 실패

3.3.1 Baseline 및 검증방법 개선

초기 모델링에서는 기존 공정변수를 이용하여 Logistic Regression, Random Forest, Isolation Forest 등의 모델을 비교하고 기본적인 불량 구분 가능성을 확인하였다. 이후 동일 Shot에서 생산된 LH/RH 제품이 동일한 공정센서 값을 공유한다는 데이터 구조가 확인됨에 따라 검증방법을 보완하였다.

CN7은 동일 TimeStamp의 제품이 학습 데이터와 검증 데이터에 동시에 포함될 경우 성능이 과대평가될 가능성이 있으므로 **TimeStamp를 Group으로 지정한 StratifiedGroupKFold**를 적용하였다. RG3는 시간에 따른 일반화 성능을 확인하기 위해 과거 생산 데이터를 학습하고 이후 생산일을 평가하는 **Chronological Split**을 유지하였다.

Model	ROC-AUC	PR-AUC	Top 5% Recall	Top 10% Recall	Top 20% Recall
Logistic Regression	0.954	0.340	64.7%	76.5%	94.1%
Random Forest	**0.962**	**0.402**	**64.7%**	**88.2%**	**100%**
XGBoost	0.960	0.325	47.1%	88.2%	100%

Random Forest가 PR-AUC와 Top-k Recall에서 비교적 안정적인 성능을 보였으며, 이후 CN7 실험은 동일한 Grouped CV 구조를 유지하여 모델 및 Feature를 비교하였다.

반면 RG3는 기존 24개 Process Feature만으로 미래 생산일의 불량을 구분하는 성능이 낮게 나타났다. EDA 결과 전체 불량이 RH 제품에 집중된 특성을 확인하여 제품 위치정보인 **Side**를 추가하고 Logistic Regression, Random Forest, XGBoost를 비교하였다. Side 추가 후 일부 분류 성능이 개선되었으나 제한된 검사범위에서의 불량 탐지 성능은 여전히 낮게 나타났다.

3.3.2 공정 기반 파생변수 및 하이퍼파라미터 실험

2.6에서 설계한 공정 기반 파생변수가 실제 예측성능에 기여하는지 확인하기 위해 기존 24개 Process Feature에 각 파생변수를 단계적으로 추가하여 성능을 비교하였다.

CN7에서는 대부분의 공정 비율 및 차이 변수가 PR-AUC와 Top-k Recall을 동시에 일관되게 개선하지 못하였다. 대표적으로 Plasticizing/Cycle Ratio를 XGBoost에 추가한 경우 Top 5% Recall은 47.1%에서 58.8%, Top 10% Recall은 88.2%에서 100%로 증가하였으나, PR-AUC는 0.325에서 0.283으로 감소하였다. 따라서 특정 지표의 개선만으로 최종 Feature를 선정하지 않고 후속 실험에서 추가적으로 검증하였다.

RG3에서도 공정 파생변수를 추가하여 비교하였으나 Process+Side 구성보다 일관된 성능 개선은 확인되지 않았다. 이에 단순 공정 비율 및 상호작용 변수를 추가하는 것만으로는 RG3의 제한적인 예측성능을 충분히 개선하기 어렵다고 판단하였다.

또한 불량 데이터 수가 매우 적다는 점을 고려하여 대규모 Grid Search 대신 Random Forest와 XGBoost에 대해 제한적인 범위의 하이퍼파라미터 조정을 수행하였다. Random Forest에서는 `n_estimators`, `max_depth`, `min_samples_leaf`, XGBoost에서는 `n_estimators`, `max_depth`, `learning_rate`를 중심으로 비교하였다.

최종 후보는 단일 지표의 최고 성능이 아니라 **PR-AUC와 Top-k Recall의 안정성을 함께 고려하여 선정**하였으며, 이후 클래스 불균형 처리 및 추가 Feature 실험을 진행하였다.

3.3.3 클래스 불균형 처리 실험

CN7과 RG3 모두 정상 데이터에 비해 불량 데이터가 매우 적은 클래스 불균형 문제가 존재한다. 이에 기존의 `class_weight="balanced"` 방식과 함께 **Random Oversampling, Random Undersampling, SMOTE**를 비교하였다. Sampling에 의한 데이터 누수를 방지하기 위해 Sampling은 학습 데이터에만 적용하고 검증 데이터에는 적용하지 않았다.

주요 결과는 다음과 같다.

금형	방법	PR-AUC	Top 5% Recall	Top 10% Recall	Top 20% Recall
CN7	Class Weight	0.397	**64.7%**	**94.1%**	**100%**
CN7	ROS	**0.411**	58.8%	82.4%	100%
CN7	RUS	0.184	58.8%	64.7%	88.2%
CN7	SMOTE	0.376	58.8%	82.4%	100%
RG3	Class Weight	0.143	20%	**30%**	30%
RG3	ROS	**0.154**	**30%**	**30%**	30%
RG3	RUS	0.073	20%	20%	**40%**
RG3	SMOTE	0.081	**30%**	**30%**	30%

CN7에서는 Random Oversampling 적용 시 PR-AUC가 일부 증가하였으나 Top 5%와 Top 10% Recall이 감소하였고, Random Undersampling과 SMOTE 역시 기존 Class Weight 방식보다 검사 우선순위 성능이 저하되었다. RG3에서도 일부 Sampling 방법이 특정 지표를 개선하였지만 ROC-AUC, PR-AUC 및 Top-k Recall을 종합적으로 고려했을 때 일관된 개선은 확인되지 않았다.

따라서 두 금형 모두 인위적인 Sampling을 최종 모델에 적용하지 않고 **Class Weight 방식**을 유지하였다. 이러한 결과는 특히 RG3의 낮은 성능이 단순한 클래스 불균형만으로 설명되기 어렵다는 추가적인 근거가 되었다.

3.3.4 모델 구조 및 시간·공정 변화정보 실험

3차 모델링 이후에는 단순 파라미터 조정보다 모델 구조와 입력정보 자체를 확장하는 방향으로 실험하였다. 이를 위해 **ExtraTrees, Soft Voting, Cyclic Hour 및 직전 Shot 대비 Delta Feature**를 순차적으로 검증하였다.

먼저 CN7에 ExtraTrees를 적용한 결과 PR-AUC가 기존 Random Forest의 0.397에서 **0.471**로 증가하였다. 반면 Random Forest와 ExtraTrees의 예측확률을 결합한 Soft Voting은 ExtraTrees 단독보다 Top 5% Recall이 감소하여 최종 후보에서 제외하였다. 이에 ExtraTrees를 CN7의 후속 실험 모델로 선정하였다.

다음으로 생산시간의 순환적 특성을 반영하기 위해 Hour 정보를 다음과 같이 변환하였다.

Hour_sin = sin(2π × Hour / 24)

Hour_cos = cos(2π × Hour / 24)

CN7에서 Cyclic Hour를 추가한 결과 PR-AUC는 0.471에서 **0.518**, Top 5% Recall은 64.7%에서 76.5%로 증가하였다. 다만 시간 자체가 불량의 직접적인 원인이라고 해석하지 않고, 공정변수에 포함되지 않은 생산시점의 설비·환경·운영상태를 간접적으로 반영할 가능성이 있는 정보로 해석하였다.

마지막으로 절대적인 공정값 뿐만 아니라 직전 Shot 대비 공정상태의 변화를 반영하기 위해 다음 4개 변수의 Delta Feature를 생성하였다.

- Max Injection Speed
- Max Injection Pressure
- Filling Time
- Plasticizing Time

CN7에서 ExtraTrees+Cyclic Hour에 4개 Delta Feature를 추가한 결과 Top 5% Recall은 76.5%에서 82.4%로 증가하였으며, 상위 5%에서 탐지된 불량 역시 13건에서 14건으로 증가하였다. 이에 해당 구성을 CN7의 최종 후보로 선정하였다.

반면 RG3에서는 ExtraTrees, Cyclic Hour 및 동일한 Delta Feature를 적용하여도 기존 Random Forest+Side보다 검사 우선순위 성능이 개선되지 않았다. 특히 RF+Side+4 Delta는 PR-AUC가 0.143에서 0.060으로 감소하고 Top 5% Recall도 20%에서 10%로 감소하였다.

RG3 구성	ROC-AUC	PR-AUC	Top 5% Recall	Top 10% Recall	Top 20% Recall
RF + Side	0.656	**0.143**	**20%**	**30%**	30%
ET + Side	**0.720**	0.065	**20%**	**30%**	30%
ET + Side + Hour	0.684	0.075	**20%**	20%	30%
RF + Side + 4 Delta	0.583	0.060	10%	10%	30%

3.3.5 RG3 RH 전용 모델 및 최근 공정 이력 검증

RG3에서는 Side를 추가한 이후 성능이 개선되었지만, 전체 불량이 RH에 집중되어 있다는 점을 고려하면 이러한 개선이 실제로 RH 내부의 정상·불량 구분능력이 향상된 결과인지 확인할 필요가 있었다.

이에 5차 모델링에서는 **RH 제품만 분리하고 Side_RH를 제거한 상태에서 기존 24개 공정변수만으로 정상과 불량을 구분할 수 있는지 추가적으로 검증하였다.**

RH-only Model	ROC-AUC	PR-AUC	Top 5% Recall	Top 10% Recall	Top 20% Recall
Random Forest	0.375	**0.169**	**20%**	**20%**	**20%**
XGBoost	**0.468**	0.135	10%	10%	10%

RH-only 평가에서 Random Forest의 ROC-AUC는 0.375, XGBoost는 0.468로 나타났으며, Random Forest는 검사범위를 Top 5%에서 Top 20%까지 확대해도 Recall이 20%에 머물렀다. 이를 통해 Side를 제외한 공정정보만으로 RH 내부의 불량 위험을 안정적으로 구분하기 어렵다는 점을 확인하였다.

직전 한 번의 Shot 변화만으로 부족할 가능성을 고려하여 Max Injection Speed, Max Injection Pressure, Cushion Position을 대상으로 최근 **5 Shot 및 20 Shot**의 평균 이탈과 표준편차를 계산하여 총 12개의 Rolling Feature를 추가하였다. 현재 Shot이 과거 기준값에 포함되지 않도록 `shift(1)` 이후 Rolling 연산을 수행하였다.

특히 Rolling Feature의 효과는 미래 Test 결과를 확인한 뒤 결정하지 않고, **10/21~10/22 Train 데이터 내부의 3-Fold Stratified Group Cross Validation에서 먼저 평가**하였다. 이는 Test 결과에 맞춰 Feature를 선택하는 문제를 줄이기 위한 것이다.

RH Train 내부 모델	ROC-AUC	PR-AUC	Top 5% Recall	Top 10% Recall	Top 20% Recall
RF + Process	**0.621**	**0.087**	**20.0%**	**20.0%**	**20.0%**
RF + Process + Rolling	0.378	0.038	0.0%	6.7%	13.3%
XGB + Process	**0.599**	**0.079**	**6.7%**	**13.3%**	**26.7%**
XGB + Process + Rolling	0.373	0.037	0.0%	6.7%	20.0%

Rolling Feature를 추가한 경우 두 모델 모두 ROC-AUC, PR-AUC 및 Top-k Recall이 전반적으로 감소하였다. 특히 Random Forest의 Top 10% Recall은 20.0%에서 6.7%로 감소하였다. 이에 Rolling 모델은 미래 Test 데이터에 적용하여 결과를 비교하지 않고 **Train 내부 검증 단계에서 후보 모델에서 제외하였다.**

5차 모델링을 통해 RG3에서는 **Side가 중요한 구분정보를 제공하지만, RH 제품 내부에서는 기존 공정변수만으로 정상·불량을 안정적으로 구분하기 어렵다는 점**을 확인하였다. 또한 Sampling, 모델 구조 변경, 시간정보, 직전 Shot 변화량뿐만 아니라 최근 5/20 Shot의 공정 이력까지 추가하여도 성능 개선이 제한적이었다.

따라서 RG3의 제한적인 성능은 단순한 클래스 불균형이나 모델 선택의 문제만으로 설명하기 어렵고, **현재 제공된 공통 설비 단위 공정센서만으로 제품 위치별 품질 차이를 충분히 표현하기 어려운 데이터 구조적 한계와 관련되어 있을 가능성**이 있다고 판단하였다.

3.4 Feature Ablation 및 최종 변수 선정

파생변수의 효과를 검증하기 위해 기본 공정변수만을 사용한 모델을 Baseline으로 설정하고, 추가 Feature를 단계적으로 결합하는 Ablation 실험을 수행하였다. 모델별 비교에서는 동일한 검증조건을 유지하여 추가 정보 자체가 검사 우선순위 성능에 미치는 영향을 확인하였다.

3.4.1 CN7 Feature Ablation

CN7은 동일 Shot의 데이터가 학습과 검증에 동시에 포함되는 것을 방지하기 위해 `TimeStamp`를 Group으로 지정한 고정된 Stratified Group K-Fold를 사용하였다.

ExtraTrees 모델을 기준으로 24개 Process Feature, Cyclic Hour, Delta Feature 및 이들의 조합을 비교한 결과는 다음과 같다.

Feature 구성	ROC-AUC	PR-AUC	Top 5% Recall	Top 10% Recall	Top 20% Recall
Process	0.9648	0.4708	64.71%	88.24%	100%
Process + Hour	0.9749	0.5180	76.47%	94.12%	100%
Process + Delta	0.9589	0.4583	58.82%	88.24%	100%
Process + Hour + Delta	**0.9747**	**0.5218**	**82.35%**	**94.12%**	**100%**

Process-only ExtraTrees 모델에서도 높은 분류 성능을 보였으나, Cyclic Hour를 추가했을 때 PR-AUC와 Top 5% Recall이 모두 향상되었다. 반면 Delta Feature만 추가한 경우 Top 5% Recall이 64.71%에서 58.82%로 감소하여 변화량 정보만으로는 충분한 개선 효과가 나타나지 않았다.

그러나 Cyclic Hour와 Delta Feature를 함께 사용한 경우 Top 5% Recall이 **82.35%**로 가장 높게 나타났다. 이는 생산시점의 특성과 직전 Shot 대비 공정변화를 함께 반영하는 것이 고위험 제품을 상위 위험군에 집중시키는 데 도움이 되었음을 보여준다.

이에 CN7 최종 모델은 **ExtraTrees**,입력변수는 **24개 Process Feature + 2개 Cyclic Hour + 4개 Delta Feature, 총 30개 변수**로 선정하였다.

3.4.2 RG3 Feature Ablation

RG3는 시간에 따른 일반화 성능을 확인하기 위해 과거 데이터를 학습하고 이후 생산 데이터를 평가하는 Chronological Split을 적용하였다. Process-only 모델을 기준으로 Side 및 시간정보를 단계적으로 추가하여 성능 변화를 확인하였다.

특히 Process-only Random Forest는 Top 5%에서 10개의 불량 중 2개, Top 10%에서도 2개를 탐지하는 데 그쳤다. `Side_RH`를 추가한 경우 Top 10%에서 탐지된 불량이 3개로 증가하고 ROC-AUC 및 PR-AUC 역시 향상되었다.

Feature 구성	ROC-AUC	PR-AUC	Top 5% Recall	Top 10% Recall	Top 20% Recall
Process-only RF	0.404	0.051	20%	20%	30%
Process + Side RF	**0.656**	**0.143**	**20%**	**30%**	**30%**

Side 정보를 추가하면서 전반적인 순위화 성능은 개선되었으나 CN7과 비교하면 검사 우선순위 성능은 여전히 제한적이었다. 이후 Hour, Cyclic Hour 및 추가적인 동적 변수를 적용하였으나 최종적인 검사 우선순위 성능의 충분한 개선은 확인되지 않았다.

따라서 복잡도를 추가하는 대신 **24개 Process Feature + `Side_RH`, 총 25개 변수**를 RG3의 최종 입력변수로 선정하였다.

3.5 추가 변수 및 외부 데이터 실험

최종 Feature 구성 외에도 모델의 성능 개선 가능성과 불량 발생에 영향을 미칠 수 있는 추가 요인을 확인하기 위해 공정이력, Shot 단위 재구성 및 외부 환경정보를 활용한 실험을 수행하였다.

먼저 CN7에서는 공정변수 간 비율·차이·상호작용 변수를 추가적으로 검토하였다. `Plasticizing/Cycle Ratio`, 사출속도와 압력의 상호작용, 충진·사출시간의 비율, 사출압력과 보압 전환 압력의 차이 등 공정적 의미를 고려한 변수를 생성하였으나, 고정된 검증조건에서 검사 우선순위 성능을 일관되게 개선하지 못하였다. 이에 최종 모델에서는 제외하였다.

RG3에서는 단일 Shot의 공정정보만으로 포착하기 어려운 생산이력을 반영하기 위해 최근 Shot의 이동평균 및 변동성을 이용한 Rolling Feature를 실험하였다. 또한 동일 Shot의 LH/RH 제품 중 하나라도 불량이면 해당 Shot을 위험 Shot으로 정의하여 Shot 단위로 데이터를 재구성하는 모델도 검토하였다. 그러나 두 접근 모두 Process+Side 모델을 대체할 정도의 충분한 검사 우선순위 성능 개선은 확인되지 않았다.

추가적으로 생산환경의 영향을 탐색하기 위해 기상청 기상관측 데이터를 결합하였다. CN7에서는 기상정보를 추가한 일부 조합에서 PR-AUC와 Top 10% Recall이 소폭 향상되었다. Process+Hour+Weather 조합의 PR-AUC는 0.5318, Top 10% Recall은 100%로 나타났다.

그러나 CN7의 전체 불량 17건이 특정 생산일에 집중되어 있어 기상조건 자체의 영향과 생산시점의 특성을 분리하기 어려웠다. 즉, 모델이 실제 기상조건에 따른 품질변화를 학습한 것이 아니라 특정 생산일을 간접적으로

구분했을 가능성을 배제할 수 없었다. 이에 시간적 교란과 과적합 위험을 고려하여 기상 데이터는 탐색적 실험에만 활용하고 최종 모델에서는 제외하였다.

RG3에서도 기상정보 추가 시 ROC-AUC와 PR-AUC가 일부 증가하였으나 검사 예산별 Recall 개선은 제한적이었다. 따라서 RG3 역시 기상정보를 최종 입력변수로 사용하지 않았다.

이러한 추가 실험을 통해 단순히 사용 가능한 모든 정보를 모델에 추가하기보다, **예측시점에서 활용 가능하고 검증조건에서 안정적인 개선이 확인되며 해석상 과도한 교란 가능성이 없는 변수만 최종 모델에 반영하였다.**

---

4. 최종 모델 및 성공·실패 조건 분석

4.1 최종 모델 구성

Feature Ablation 및 추가 실험 결과를 바탕으로 CN7과 RG3의 데이터 특성에 맞추어 각각 별도의 최종 모델을 선정하였다.

CN7은 **ExtraTrees Classifier**를 최종 모델로 사용하였다. 입력변수는 24개 기본 공정변수와 2개의 Cyclic Hour, 4개의 Delta Feature를 결합한 총 30개 변수로 구성하였다.

RG3는 **Random Forest Classifier**를 최종 모델로 사용하였다. 입력변수는 24개 기본 공정변수와 제품 위치를 나타내는 `Side_RH`를 결합한 총 25개 변수로 구성하였다.

구분	CN7	RG3
최종 모델	ExtraTrees	Random Forest
학습 데이터	1,211건	1,182건
불량	17건	25건
기본 Process	24개	24개
추가 Feature	Cyclic Hour 2개 + Delta 4개	Side_RH 1개
최종 Feature 수	**30개**	**25개**
검증 방법	Stratified Group K-Fold	Chronological Split

두 모델 모두 단순한 정상/불량 판정만을 목적으로 하지 않고, 예측된 Risk Score를 기준으로 제품을 정렬하여 **제한된 검사 자원을 고위험 제품에 우선 배분하는 검사 우선순위 모델**로 활용하는 것을 목표로 하였다.

4.2 CN7 최종 성능 및 검사 우선순위 효과

CN7 최종 모델은 ROC-AUC 0.9747, PR-AUC 0.5218을 기록하였다. 특히 본 연구에서는 단순 분류성능뿐만 아니라 제한된 검사 자원에서 실제 불량을 얼마나 탐지할 수 있는지를 확인하기 위해 Inspection Budget에 따른 Recall을 분석하였다.

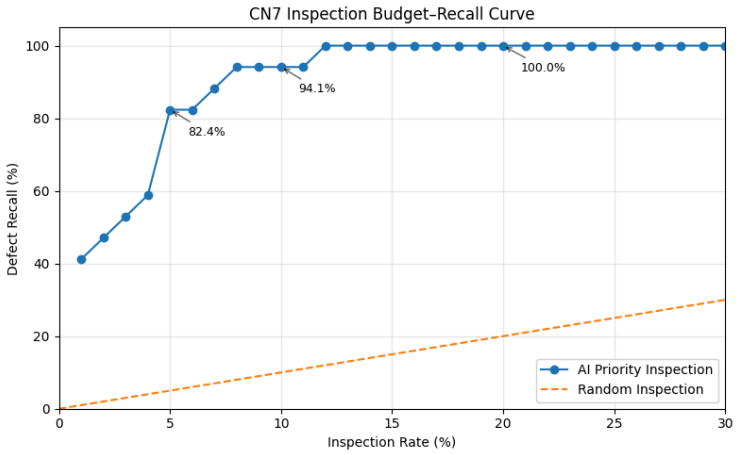


그림 4.2 CN7 Inspection Budget–Recall Curve

그림 4.2는 Risk Score가 높은 제품부터 순차적으로 검사했을 때 검사 대상 비율에 따른 불량 탐지율을 나타낸다. 주황색 점선은 검사 대상을 무작위로 선정했을 경우의 기대 탐지율이며, 파란색 실선은 CN7 최종 모델의 Risk Score를 이용하여 검사 우선순위를 결정한 결과이다.

모델 기반 우선검사의 경우 전체 제품의 약 5%만 검사했을 때 전체 불량의 82.35%를 탐지하였으며, 검사범위를 10%로 확대하면 94.12%, 20%에서는 100%의 불량이 검사 대상에 포함되었다. 동일한 검사 비율에서 무작위 검사보다 불량이 상위 위험군에 집중되어 있어 Risk Score가 검사 대상의 우선순위를 결정하는 데 유효함을 확인하였다.

검사 대상	검사 제품 수	탐지 불량	Recall	Precision
Top 5%	61건	14/17	82.35%	22.95%
Top 10%	122건	16/17	94.12%	13.11%
Top 20%	243건	17/17	100%	7.00%

특히 상위 5%인 61건에 전체 불량 17건 중 14건이 포함되어, 전체 제품을 동일한 우선순위로 검사하는 것보다 고위험 제품에 검사를 집중할 수 있음을 확인하였다. 다만 해당 결과는 검증 데이터에서 확인된 성능으로, 실제 생산환경에서도 동일한 탐지율이 보장된다는 의미는 아니다.

CN7에서 모델이 높은 위험도를 부여한 불량 사례를 추가적으로 분석한 결과, 일부 불량 구간에서는 **Max_Injection_Speed, Filling_Time, Injection_Time, Cushion_Position, Max_Injection_Pressure 등 여러 공정변수가 동시에 크게 변화하는 복합적인 공정상태 이상**이 관찰되었다. 이러한 경우에는 공정변수의 변화가 비교적 뚜렷하게 나타나 최종 모델이 불량 제품을 상위 위험군으로 분류하는 데 유리했던 것으로 판단된다.

반면 모든 CN7 불량에서 이러한 명확한 공정 이상이 나타난 것은 아니었다. 일부 가스 불량에서는 개별 공정변수의 뚜렷한 이상이 관찰되지 않았으며, **전체 17개 불량 중 11개(64.71%)는 동일한 공정변수 값을 가진 제품에서 정상과 불량 라벨이 함께 존재하는 Label Conflict에 포함**되어 있었다. 따라서 현재 공정변수만으로 개별 제품의 품질 차이를 완전히 설명하는 데에는 한계가 존재한다.

CN7 최종 모델에서는 공정변수뿐만 아니라 생산시간의 주기적 특성을 나타내는 **Cyclic Hour**와 직전 Shot 대비 공정변화를 나타내는 **Delta Feature**를 함께 활용하였다. 이를 통해 단일 변수의 극단적인 이상뿐만 아니라 생산 시점과 연속적인 공정상태 변화까지 위험도 산정에 반영하였으며, 이러한 특징이 높은 검사 우선순위 성능에 기여한 것으로 판단된다. 다만 시간정보 역시 특정 생산시점의 잠재적인 조건을 간접적으로 반영할 가능성이 있으므로, 이를 불량의 직접적인 원인으로 해석하지 않았다.

따라서 CN7에서는 **복수의 공정변수 변화와 시간적·연속적 공정 패턴이 나타나는 조건에서 비교적 효과적인 위험도 분류가 가능했던 반면, 동일 Shot 내 제품별 품질 차이와 같이 현재 센서정보에 나타나지 않는 불량에서는 예측에 한계가 존재하는 것**으로 분석하였다.

4.3 RG3 최종 성능 및 검사 우선순위 효과

RG3 최종 모델에 대해 위험도 점수(Risk Score)가 높은 제품부터 우선적으로 검사하는 방식으로 검사 비율에 따른 불량 탐지 성능을 분석하였다. 최종 모델은 **24개 공정변수와 제품 위치를 나타내는 Side_RH 변수를 입력으로 사용하는 Random Forest 모델**이며, 시간 순서를 고려하여 이전 생산 데이터를 학습 데이터로 사용하고 이후 생산 데이터를 평가 데이터로 구성하였다.

평가 데이터는 총 **500건이며 이 중 불량은 10건**이다. 위험도 상위 5%에 해당하는 25건을 우선 검사한 결과, 전체 불량 10건 중 2건을 탐지하여 **Recall 20%**를 기록하였다. 검사범위를 상위 10%인 50건으로 확대하면 3건을 탐지하여 **Recall 30%**를 기록하였다. 그러나 상위 20%인 100건까지 검사범위를 확대하여도 추가적인 불량이 탐지되지 않아 Recall은 **30%**에 머물렀다.

검사 비율	검사 제품 수	탐지 불량	Recall	Precision
5%	25	2/10	20%	8%
10%	50	3/10	30%	6%
20%	100	3/10	30%	3%

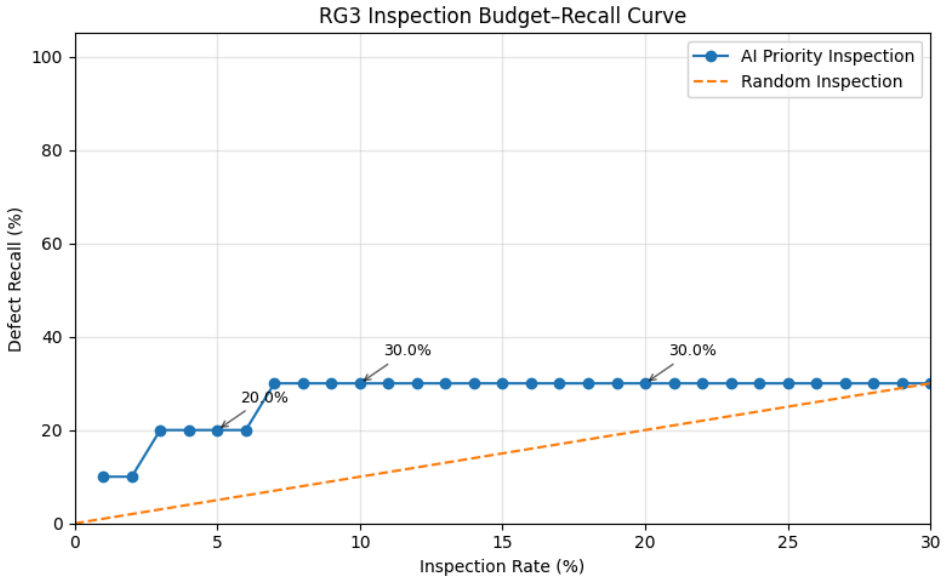


그림 4.3 RG3 Inspection Budget–Recall Curve

그림 4.3는 RG3 모델의 Risk Score를 기준으로 위험도가 높은 제품부터 검사했을 때 검사 비율에 따른 불량 탐지율을 나타낸다. CN7에서는 검사 비율 증가에 따라 높은 불량 탐지율을 확보한 반면, RG3에서는 상위 10% 이후 검사범위를 확대하여도 Recall이 증가하지 않았다. 이는 **현재 모델의 입력정보만으로 RG3 불량 제품의 위험도를 충분히 분리하는 데 한계가 있음을 보여준다.**

이러한 결과를 단순한 모델 성능 저하로 판단하지 않고 미탐지 사례와 데이터 구조를 함께 분석하였다. 2장에서 확인한 바와 같이 RG3의 전체 25개 불량은 동일 Shot에서 LH는 정상, RH는 불량으로 판정되는 Label

Conflict에 포함되어 있었으며, 해당 LH/RH 제품의 24개 공정변수 값은 동일하였다. 즉, 동일한 설비 공정정보를 가진 제품에 서로 다른 품질 결과가 존재하는 구조로 인해 공정변수만으로 개별 제품의 품질 차이를 구분하는 데 한계가 있었다.

이를 보완하기 위해 제품 위치정보인 Side_RH 변수를 모델에 추가하였으나, Side_RH는 LH와 RH의 위치 차이를 제공할 뿐 RH 제품 내부에서 실제 불량 제품을 구분할 수 있는 추가적인 공정정보를 제공하지는 않는다. 따라서 RG3의 제한적인 예측성능은 단순한 모델 복잡도의 부족보다는 **현재 관측된 설비 단위 공정변수가 개별 제품의 품질 차이를 충분히 설명하지 못하는 정보적 한계**와 관련된 것으로 판단하였다.

향후 제품 위치별 금형 온도나 캐비티 압력 등 위치별 공정상태를 나타낼 수 있는 추가 센서정보가 확보된다면 이러한 한계를 보완할 가능성이 있다. 다만 현재 데이터만으로 구체적인 물리적 불량 원인을 확정할 수는 없다.

4.4 CN7과 RG3의 성공·실패 조건 비교

두 제품의 분석 결과는 동일한 사출성형 데이터에서도 모델의 활용 가능성이 데이터가 포함하고 있는 품질정보의 수준에 따라 크게 달라질 수 있음을 보여준다.

구분	CN7	RG3
최종 모델	ExtraTrees	Random Forest
최종 Feature	Process + Hour + Delta	Process + Side
ROC-AUC	**0.9747**	0.6557
PR-AUC	**0.5218**	0.1432
Top 5% Recall	**82.35%**	20%
Top 10% Recall	**94.12%**	30%
Top 20% Recall	**100%**	30%
전체 불량 중 Conflict 포함	64.71%	**100%**
주요 특징	복합 공정이상 및 시간·변화량 정보 활용 가능	동일 Shot의 제품별 품질차이 구분 한계

CN7에서는 공정변수와 시간 및 Shot 변화정보를 결합함으로써 고위험 제품을 상위 Risk Score 구간에 집중시키는 것이 가능하였다. 따라서 제한된 검사자원을 고위험 제품에 우선 배분하는 **검사 우선순위 시스템으로서의 활용 가능성**을 확인하였다.

반면 RG3에서는 Side 정보를 추가하여 Process-only 모델보다 전반적인 위험도 구분 성능을 개선할 수 있었으나, 검사 예산을 확대해도 Recall 증가가 제한적이었다. 특히 전체 불량이 동일 Process Feature를 가진 정상 LH와 쌍을 이루는 구조가 확인되어 현재 센서 구성만으로 개별 제품 품질을 구분하는 데 한계가 있음을 확인하였다.

따라서 본 연구의 결과는 **CN7에서는 위험도 기반 검사 우선순위 모델의 가능성을 확인하고, RG3에서는 모델이 실패하는 조건을 데이터 구조 차원에서 규명했다는 점**에 의미가 있다.

4.5 오분류 사례 및 공정조건 분석

최종 모델의 오류 특성을 확인하기 위해 실제 불량임에도 검사 우선순위 상위 구간에 포함되지 않은 False Negative(FN)와 정상 제품임에도 높은 Risk Score를 부여받은 **False Positive(FP)** 사례를 분석하였다.

CN7에서는 일부 불량 구간에서 Max Injection Speed, Filling Time, Injection Time, Cushion Position, Max Injection Pressure 등 복수 공정변수의 동시적인 변화가 관찰되었으며, 이러한 공정상태가 나타난 제품은 상대적으로 높은 Risk Score에 배치되는 경향을 보였다. 반면 일부 불량은 개별 공정변수에서 뚜렷한 이상이 나타나지 않았으며, 특히 동일 Shot의 LH/RH가 동일한 24개 공정값을 가지면서 서로 다른 품질결과를

갖는 Label Conflict가 전체 불량 17건 중 11건(64.7%)을 차지하였다. 이러한 경우 현재 입력정보만으로 개별 제품의 품질 차이를 구분하기 어려워 FN이 발생할 수 있는 구조적 조건으로 판단하였다.

RG3에서는 이러한 한계가 더욱 명확하게 나타났다. 전체 불량 25건이 동일 Shot의 LH 정상/RH 불량 형태의 Label Conflict에 포함되었으며, 해당 LH/RH 제품의 24개 공정변수는 동일하였다. Side_RH를 추가하여 제품 위치정보를 반영하였으나 RH 내부의 정상·불량 구분성능은 낮게 나타났다. 따라서 RG3의 FN은 단순한 모델 복잡도 부족보다는 현재 설비 단위 공정센서가 제품 위치별 품질 차이를 충분히 표현하지 못하는 정보적 한계와 관련된 것으로 분석하였다.

한편 FP는 실제로는 정상으로 판정되었으나 모델이 학습한 불량 발생구간과 유사한 공정상태 또는 시간적 패턴을 가진 제품에 높은 Risk Score가 부여되면서 발생할 수 있다. 본 연구에서는 Risk Score를 최종 품질판정이 아닌 **검사 우선순위 결정 지표**로 활용함으로써 이러한 FP를 즉시 불량으로 판정하는 대신 우선검사 대상으로 활용하였다.

---

5. 미라벨 데이터 적용 및 검사 우선순위 제안

5.1 최종 모델 구성

최종적으로 CN7과 RG3의 서로 다른 데이터 특성을 반영하여 금형별 모델을 각각 구성하였다.

구분	CN7	RG3
최종 모델	ExtraTrees	RandomForest
기본 Process	24개	24개
추가 변수	Cyclic Hour 2개 + Delta 4개	Side_RH
총 입력변수	30개	25개
학습 데이터	1,211	1,182
불량 데이터	17	25

5.2 미라벨 데이터 Risk Score 산출

최종 모델을 학습 데이터 전체로 재학습한 후 KAMP에서 제공한 미라벨 데이터에 적용하였다.

CN7 35,239건과 RG3 35,941건, 총 **71,180건**의 제품에 대해 Risk Score를 산출하였다.

구분	CN7	RG3
적용 데이터	35,239건	35,941건
평균 Risk Score	0.0392	0.0173
최대 Risk Score	0.2378	0.1486
최종 활용	검사 우선순위	보조적 위험지표

두 모델은 서로 다른 데이터와 Feature를 기반으로 독립적으로 학습되었으므로 CN7과 RG3의 Risk Score 절대값을 직접 비교하지 않았다. 각 모델에서 산출된 점수는 해당 금형 내부에서 제품 간 상대적인 위험 순위를 결정하는 용도로만 활용하였다.

5.3 위험군 분류

위험군의 기준은 앞선 Inspection Budget 분석에서 사용한 검사 비율을 바탕으로 설정하였다. 상위 5%를 우선검사 대상인 High 그룹으로 정의하고, 추가적인 검사 여력이 있을 경우 검사범위를 확대할 수 있도록 5~20% 구간을 Medium 그룹으로 설정하였다. 나머지 제품은 Low 그룹으로 분류하였다. 이 구분은 절대적인 품질 판정 기준이 아니라 제한된 검사 자원을 위험도가 높은 제품에 우선 배분하기 위한 운영 기준이다.

위험군	CN7	RG3
High	1,761	1,797
Medium	5,286	5,391
Low	28,192	28,753
전체	35,239	35,941

CN7은 검증 단계에서 상위 위험군에 실제 불량이 효과적으로 집중되는 결과를 확인했기 때문에 검사 우선순위 결정에 활용할 가능성이 있다고 판단하였다.

반면 RG3는 검증 성능이 제한적이므로 High 그룹을 실제 불량 판정 결과로 사용하기보다는 추가 검사가 필요한 제품을 선별하는 **보조적 위험지표**로 해석하였다.

5.4 위험도 기반 검사 프로세스 제안

최종적으로 다음과 같은 검사 프로세스를 제안하였다.

공정센서 및 생산정보 수집 → 금형별 Feature 생성 → Risk Score 산출 → High/Medium/Low 위험군 분류 → 위험도 기반 검사 우선순위 결정 → 실제 품질검사 → 검사결과 축적 및 모델 재학습

실제 품질검사에서 확보된 결과는 새로운 라벨 데이터로 축적하여 주기적인 모델 재학습 및 성능 검증에 활용할 수 있다. 특히 생산조건이나 설비상태가 시간에 따라 변화할 수 있으므로 과거에 학습된 모델의 Risk Score를 고정적으로 사용하는 것보다, 신규 검사결과를 지속적으로 축적하여 모델의 성능을 재검증하는 과정이 필요하다.

본 시스템은 기존 품질검사를 완전히 대체하는 자동 판정 시스템이 아니라 **제한된 검사 자원을 위험도가 높은 제품에 우선 배분하기 위한 의사결정 지원 시스템**으로 활용하는 것을 목표로 한다. 따라서 Low 위험군 역시 불량이 발생하지 않는다고 보장할 수 없으며, 신규 생산기간이나 공정조건 변화 시 기존 검증성능이 유지되는지 재검증할 필요가 있다. 또한 RG3와 같이 현재 센서정보만으로 개별 제품의 품질 차이를 충분히 설명하기 어려운 경우에는 **제품 위치별 공정상태를 관측할 수 있는 추가 센서정보의 확보와 이를 활용한 모델 재검증이 필요하다.**

---

6. 결론 및 한계

6.1 주요 연구 결과

본 연구에서는 KAMP 사출성형 데이터를 활용하여 단순 정상·불량 분류를 넘어 **불량 위험도 기반 검사 우선순위 시스템**을 구축하였다.

원천 데이터와 가공 데이터를 연결하여 생산 시각과 제품 위치 정보를 복원하고, 동일 shot에서 동일한 공정변수를 공유하면서 품질 결과가 달라지는 Label Conflict 구조를 발견하였다.

CN7에서는 데이터 누수를 방지한 그룹 기반 교차검증에서도 최종 ExtraTrees 모델이 위험도 상위 5% 검사 시 전체 불량의 **82.35%**, 상위 10% 검사 시 94.12%를 탐지하여 검사 우선순위 모델로서의 활용 가능성을 확인하였다.

반면 RG3에서는 모든 불량이 RH에 집중되어 있었으며, 동일 Shot의 LH/RH가 같은 공정정보를 공유하면서도 품질 결과가 다른 사례가 확인되었다. 제품 위치를 추가하였으나 이후 날짜 평가에서 상위 10% 검사 시 불량 10건 중 3건을 포착하는 데 그쳤다.

따라서 높은 성능을 보인 조건과 예측이 어려운 조건을 데이터 구조 및 관측 정보의 범위와 함께 분석하였다. 최종적으로 두 제품의 전체 라벨 데이터로 모델을 재학습하고, 미라벨 71,180건에 제품별 Risk Score와 검사 우선순위를 생성하였다.

6.2 연구의 한계

검증 결과의 일반화 범위. CN7의 14/17 포착은 TimeStamp 그룹을 기준으로 한 4-fold 교차검증의 OOF 예측을 모아 평가한 결과이다. 각 행은 해당 행을 학습에 사용하지 않은 모델로 예측했으나 날짜 순서로 분할한 검증은 아니다. 불량 17건이 특정 생산시점에 집중되어 있으므로 미래 생산기간에도 같은 탐지율이 유지된다고 해석할 수 없다.

모델 선택과 희소 불량의 영향. 여러 모델과 파생변수를 같은 개발 검증에서 비교하였으므로 선택 편향이 남는다. RG3는 2020년 10월 23일 이전의 682건·불량 15건으로 학습하고 그날 이후 500건·불량 10건을 평가했으나, 이 구간도 반복 실험에 사용하여 완전히 독립적인 최종 시험으로 보기는 어렵다. 소수 불량에서는 포착 한두 건에도 지표가 크게 달라진다.

공정 입력의 정보 한계. Label Conflict는 24개 공정변수가 같은데 품질 라벨이 다른 경우를 뜻한다. Side_RH를 추가하면 입력의 구별 가능성은 달라지므로 이를 모든 입력에서의 예측 불가능성이나 라벨 오류로 단정하지 않는다. RH 내부의 품질 차이를 설명할 추가 정보와 생산기간 변화의 영향도 함께 검토해야 한다.

학습·추론 전처리의 일관성. 제출 코드에서 CN7 학습용 Hour는 정수 시각을 사용하고 미라벨 추론용 Hour는 분·초를 포함하여 계산한다. 이는 학습·추론의 변환 불일치로, 시간변수 정의를 통일한 뒤 검증과 추론을 함께 재실행해야 한다. Delta는 라벨 자료와 미라벨 자료에서 각각 직전 관측 Shot 대비로 계산하므로 관측 공백이 있으면 실제 직전 생산 사이클의 변화량과 다를 수 있다.

재현 범위와 전처리 계보. 저장된 결과는 제출 당시의 실행 출력이다. 버전이 고정된 실행환경과 원천부터 최종 학습 CSV를 생성하는 전체 처리 과정은 추가 정리가 필요하다. 가공 공정변수의 표준화가 어떤 범위에서 수행되었는지도 확인해야 한다. 독립적인 재실행을 통한 수치 재현과 실행환경 고정은 후속 검증 과제로 남는다.

점수와 운영 기준의 해석. Risk Score는 제품군 내 상대적 검사 우선순위이며 보정된 절대 불량 확률이 아니다. CN7과 RG3 점수의 절대값을 직접 비교하지 않으며, High/Medium/Low 구간도 실제 불량 판정이나 검사 생략의 근거가 아니다. 71,180건은 미라벨 추론 규모이므로 정답 기반 검증 건수로 해석하지 않는다.

6.3 향후 발전 방향

첫째, 전처리 일관성과 재현성을 확보한다. CN7의 시간변수 정의를 학습·추론에 공통으로 적용하고 기존 결과와 구분하여 재검증한다. 원천·가공 데이터 연결 규칙, Shot 정의, 관측 공백 처리 및 파생변수 생성 과정을 명문화한다. 데이터 분할 이후 적합해야 하는 전처리를 구분하고 패키지 버전과 실행 설정을 함께 기록한다.

둘째, 이후 생산기간의 성능을 검증한다. CN7에는 과거 생산 데이터로 학습하고 이후 기간을 평가하는 시간 검증을 추가한다. 복수의 그룹 분할에서도 검사 예산별 불량 포착이 유지되는지 확인하되, 같은 자료를 반복 분할한 결과와 새로운 생산기간의 검증을 구분한다. 생산시점별 분포 변화와 오경보·미검출을 함께 추적한다.

셋째, 개별 제품의 품질을 설명할 정보를 확충한다. 제품 위치별 금형 온도, 캐비티 압력, 검사 영상 등 제품 단위 정보를 검토한다. 추가 정보가 확보되면 동일한 검증 조건에서 기존 입력 대비 개선 여부를 확인하며, 관측된 LH/RH 차이를 특정 물리적 원인으로 미리 확정하지 않는다.

넷째, 검사 의사결정에 필요한 조건을 평가한다. 입력 공정값이 확정되는 시각과 실제 품질검사 시각을 확인하여 검사 이전의 점수 산출 가능성을 검증한다. 검사 가능 수량, 오경보에 따른 추가 검사 부담 및 불량 미검출 비용을 고려해 우선순위 정책을 평가한다. MES와 연계할 경우에도 품질검사를 대체하기보다 검사 대상을 제안하는 의사결정 지원을 목표로 한다.

데이터의 출처와 활용 범위는 참고문헌에 명시하였다. 원본·가공 데이터와 행 단위 예측 결과는 저장소에 재배포하지 않으며, 정확한 배포 버전과 이용 조건은 제공 가이드 및 대회 규정을 기준으로 확인한다.

참고문헌 및 데이터 출처

[1] Korea AI Manufacturing Platform(KAMP). 「사출성형기 AI 데이터셋」 및 관련 제공 자료. https://www.kamp-ai.kr/

[2] KAMP. 제조데이터 분석 경진대회 제공 사출성형 공정 데이터(CN7·RG3). 본 연구의 학습·검증 및 미라벨 추론에 활용한 대회 배포 자료.

[3] 기상청. 기상자료 API 허브, 종관기상관측(ASOS) 자료. https://apihub.kma.go.kr/ 기상정보 결합 탐색 실험에 활용하였으며 최종 모델 입력에서는 제외하였다.